

Rapport Technique – Pipeline de Données et Visualisation du Conflit en Ukraine (2014–2022)

Auteur : Dylan Llodra et Nicolas Gréault

Outil principal : Power BI Desktop

Technologies : Power Query (M), CSV, Modèle tabulaire Power BI

1. Introduction

Ce projet vise à analyser les conflits armés en Ukraine entre 2014 et 2022 à partir de plusieurs sources ouvertes. L'objectif est de concevoir une chaîne de traitement robuste permettant :

- L'intégration de données hétérogènes,
- Leur nettoyage et enrichissement,
- La consolidation multi-sources,
- La visualisation interactive à destination des décideurs.

L'architecture adoptée suit le modèle **Medallion Architecture (Bronze / Silver / Gold)** afin de garantir la qualité, la traçabilité et la performance analytique.

2. Architecture globale du projet

2.1 Organisation des couches

Le projet est structuré en trois niveaux :

Bronze (Raw)

- Fichiers CSV sources
- Données non modifiées
- Conservation du format original

Sources principales :

- ACLED (événements de conflits)
- UCDP (données de violence et mortalité)

Silver (Nettoyage et enrichissement)

- Typage strict des colonnes
- Harmonisation des noms

- Nettoyage des valeurs manquantes
- Enrichissement temporel
- Normalisation géographique

Tables Silver :

- [SILVER]2019-07-16-2022-07-24-Ukraine
- [SILVER]conflict_data_ukr

Gold (Modèle analytique)

- Fusion multi-sources
- Normalisation sémantique
- Suppression des colonnes inutiles
- Création de mesures métiers

Tables Gold :

- [GOLD]ukraine_2014_2022
 - [GOLD]Mesures_Globales
-

3. Pipeline ETL – Source ACLED

3.1 Chargement

Chargement du fichier CSV contenant les événements :

- Délimiteur : “,”
- Encodage : Windows-1252
- 31 colonnes

3.2 Promotion des en-têtes

Les premières lignes sont converties en noms de colonnes afin d’obtenir un schéma exploitable.

3.3 Typage des données

Typage strict des colonnes critiques :

- Dates → type date
- Coordonnées → number
- Identifiants → Int64

Cela permet :

- d’éviter les erreurs de calcul,

- d'améliorer les performances,
- d'assurer la cohérence analytique.

3.4 Harmonisation des noms

Standardisation des colonnes :

- data_id → id
- iso → code_ISO_country
- event_date → start_event_date

Objectif : aligner les noms entre sources.

3.5 Nettoyage des valeurs manquantes

Remplacement des valeurs vides par :

"no information"

Sur les colonnes textuelles sensibles :

- acteurs
- zones administratives

3.6 Enrichissement métier

Calcul des morts civiles

Création d'une colonne calculée :

- Analyse des champs actor1 et actor2
- Si présence du mot civilians
- Attribution des fatalités à fatalities_civilians

Cela permet une analyse différenciée :

- pertes civiles
- pertes militaires

3.7 Conversion du timestamp Unix

Transformation du timestamp en date réelle :

- Base : 01/01/1970
- Ajout de la durée en secondes

Résultat :

- end_event_date
-

4. Pipeline ETL – Source UCDP

4.1 Chargement et nettoyage initial

- Encodage UTF-8
- Suppression de la première ligne parasite
- Suppression des lignes en erreur

4.2 Typage et normalisation

Colonnes critiques :

- années
- coordonnées
- dates début/fin

Conversion des formats américains vers standards Power BI.

4.3 Enrichissement sémantique

Création d'une colonne event_type à partir du code type_of_violence :

Code	Traduction
1	State armed conflict
2	Non-state violence
Autre	Not specified

4.4 Nettoyage texte

Uniformisation des libellés administratifs et géographiques.

5. Consolidation Gold – Ukraine 2014–2022

5.1 Fusion multi-sources

Utilisation de :

Table.Combine()

Objectif :

- agréger ACLED + UCDP
- produire une table analytique unique

5.2 Suppression des colonnes inutiles

Optimisation du modèle :

- suppression des colonnes techniques
- retrait des métadonnées inutiles
- réduction mémoire

5.3 Harmonisation géographique

Normalisation manuelle des régions :

- Kyiv City → Kyiv
- Odessa Oblast → Odesa
- Autonomous Republic of Crimea → Crimea

5.4 Normalisation régionale

Correction automatique :

- valeurs nulles remplacées par Europe
-

6. Modèle analytique Power BI

6.1 Tables principales

- Ukraine_2014_2022
- Mesures_Globales

6.2 Mesures calculées

Principaux KPI :

- Nombre total d'événements
- Total fatalities
- Décès civils
- Décès militaires
- Nombre de régions impactées

6.3 Relations

Relations basées sur :

- Dates
 - Régions
 - Types d'événements
-

7. Visualisations du Dashboard

7.1 Analyse temporelle

- évolution annuelle
- évolution mensuelle
- pics de violence

7.2 Analyse géographique

- Carte Azure Maps
- densité d'événements
- concentration des décès

7.3 Analyse par type

- Battles
- Explosions
- Violence against civilians

7.4 Analyse avancée

- corrélation durée / décès
 - comparaison inter-annuelle
 - analyse multi-dimensionnelle
-

8. Performance et optimisation

8.1 Bonnes pratiques appliquées

- typage en amont
- suppression colonnes inutiles
- calculs déplacés dans Power Query
- réduction cardinalité texte

8.2 Avantages obtenus

- modèle plus léger
 - temps de chargement réduit
 - meilleure réactivité dashboard
-

9. Limites du projet

- dépendance aux sources ouvertes
- possibles biais de déclaration

- données incomplètes pour certaines régions
-

10. Perspectives d'amélioration

- ajout de données ONU
 - intégration temps réel
 - modèle prédictif
 - segmentation par acteurs
 - analyse de corrélation économique
-

Conclusion

Ce projet démontre :

- la robustesse d'une architecture Medallion
- l'efficacité de Power Query pour l'ETL
- la valeur stratégique d'un dashboard décisionnel

Il constitue une base solide pour des analyses géopolitiques avancées et une aide à la décision institutionnelle.